

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ «НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ИТМО»

Факультет программной инженерии

Дисциплина: Математическая статистика

Лабораторная работа №4

Тема: «Простая линейная регрессия»

Вариант 5

Выполнила:

Исаева А-И.А.

Преподаватель:

Ланбин Ю.В

Санкт-Петербург, 2026

Содержание

1	Исходные данные	2
2	Диаграмма рассеяния	2
3	Оценка коэффициентов регрессии	3
4	Прогнозные значения и остатки	3
5	Оценка дисперсии ошибки	3
6	Доверительные интервалы для коэффициентов	4
7	Доверительный интервал для функции регрессии	4
8	Коэффициент детерминации	5
9	Выводы	5

Цель работы

Освоить методы оценивания параметров простой линейной регрессии, построения доверительных интервалов для коэффициентов регрессии и доверительного интервала для средней функции регрессии.

1 Исходные данные

Общее количество наблюдений: $n = 50$. Первые 5 строк исходных данных представлены в таблице 1.

Таблица 1: Исходные данные

№	x	y
1	0.5966	6.9824
2	1.5259	5.3286
3	1.6426	5.2720
4	1.7729	7.8449
5	1.9611	5.1646

2 Диаграмма рассеяния

На рисунке 1 представлена диаграмма рассеяния зависимости y от x . По графику можно предположить наличие положительной линейной связи между переменными.




Рис. 1: Диаграмма рассеяния y от x

3 Оценка коэффициентов регрессии

Выборочные средние:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 6.0420, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = 10.1603.$$

Вспомогательные суммы:

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 446.2544, \quad S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = 429.0738.$$

Оценки коэффициентов:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{429.0738}{446.2544} = 0.9615, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 10.1603 - 0.9615 \cdot 6.0420 = 4.3509.$$

Уравнение регрессии:

$$\hat{y} = 4.3509 + 0.9615x.$$

4 Прогнозные значения и остатки

Для каждого наблюдения вычислены прогнозные значения $\hat{y}_i$ и остатки $e_i = y_i - \hat{y}_i$. В таблице 2 приведены первые 10 строк.

Таблица 2: Прогнозные значения и остатки

x	y	$\hat{y}$	e	e^2
0.5966	6.9824	4.9245	2.0579	4.2349
1.5259	5.3286	5.8180	-0.4894	0.2395
1.6426	5.2720	5.9302	-0.6582	0.4333
1.7729	7.8449	6.0555	1.7894	3.2019
1.9611	5.1646	6.2365	-1.0719	1.1489
2.0533	5.9850	6.3251	-0.3401	0.1157
2.2539	5.0892	6.5180	-1.4288	2.0415
2.7119	7.4560	6.9584	0.4976	0.2476
2.7864	11.1629	7.0300	4.1329	17.0809
2.8279	6.7935	7.0699	-0.2764	0.0764

5 Оценка дисперсии ошибки

Остаточная сумма квадратов:

$$RSS = \sum_{i=1}^n e_i^2 = 151.2872.$$

Несмещённая оценка дисперсии ошибки:

$$s^2 = \frac{RSS}{n-2} = \frac{151.2872}{48} = 3.1518.$$

Остаточное стандартное отклонение:

$$s = \sqrt{s^2} = 1.7753.$$

6 Доверительные интервалы для коэффициентов

Критическое значение распределения Стьюдента при $\alpha = 0.05$ и $df = n - 2 = 48$:

$$t_{kp} = t_{1-\alpha/2; 48} = 2.0106.$$

Стандартные ошибки коэффициентов:

$$SE(\hat{\beta}_1) = \frac{s}{\sqrt{S_{xx}}} = \frac{1.7753}{\sqrt{446.2544}} = 0.0840,$$

$$SE(\hat{\beta}_0) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} = 1.7753 \sqrt{\frac{1}{50} + \frac{6.0420^2}{446.2544}} = 0.5665.$$

95% доверительные интервалы:

$$\beta_0 : \hat{\beta}_0 \pm t_{kp} SE(\hat{\beta}_0) = 4.3509 \pm 2.0106 \cdot 0.5665 = [3.2119, 5.4898],$$

$$\beta_1 : \hat{\beta}_1 \pm t_{kp} SE(\hat{\beta}_1) = 0.9615 \pm 2.0106 \cdot 0.0840 = [0.7925, 1.1305].$$

Поскольку доверительный интервал для β_1 не содержит нуля, линейная зависимость между x и y является статистически значимой на уровне 5%.

7 Доверительный интервал для функции регрессии

На рисунке 2 изображены исходные точки, оценённая прямая регрессии, а также нижняя и верхняя границы 95% доверительного интервала для средней функции регрессии $E(Y|x)$. Интервал наиболее узкий вблизи среднего значения $\bar{x} = 6.0420$ и расширяется к краям диапазона.




Рис. 2: Линия регрессии и 95% доверительный интервал для $E(Y|x)$

8 Коэффициент детерминации

Общая сумма квадратов:

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2 = 563.8418.$$

Коэффициент детерминации:

$$R^2 = 1 - \frac{RSS}{TSS} = 1 - \frac{151.2872}{563.8418} = 0.7317.$$

Это означает, что 73.17% изменчивости зависимой переменной y объясняется построенной линейной регрессионной моделью.

9 Выводы

1. Полученное уравнение регрессии: $\hat{y} = 4.3509 + 0.9615x$.
2. Коэффициент $\beta_1 = 0.9615 > 0$, следовательно, зависимость между x и y положительная.
3. 95% доверительный интервал для β_1 равен $[0.7925; 1.1305]$. Ноль не попадает в этот интервал.
4. Линейная зависимость статистически значима на уровне значимости 5% (так как доверительный интервал для β_1 не содержит нуля).
5. Доверительный интервал для функции регрессии наиболее узкий вблизи среднего значения x (примерно в центре графика) и расширяется к краям.
6. Коэффициент детерминации $R^2 = 0.7317$ показывает, что модель объясняет большую часть изменчивости y . По графику видно, что точки достаточно хорошо следуют за прямой, но присутствует заметный разброс, что согласуется с $R^2 \approx 0.73$.