

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ «НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ИТМО»

Факультет программной инженерии

Дисциплина: Математическая статистика

РАСЧЕТНО-ГРАФИЧЕСКАЯ РАБОТА №3

Тема: «Регрессионные модели и их интерпретация»

Вариант А-5

Выполнили студенты:

Исаева А-И.А.

Соснина А.В.

Преподаватель:

Ланбин Ю.В

Санкт-Петербург, 2026

Содержание

1	Введение и исходные данные	2
2	Диаграмма рассеяния и гипотеза о характере связи	2
3	Построение моделей	3
3.1	Линейная и квадратичная модели	3
3.2	Степенная модель	4
4	Сравнение моделей	4
5	Анализ линейной модели	5
5.1	Остатки, RSS и дисперсия ошибки	5
5.2	Доверительные интервалы для коэффициентов	6
6	Прогноз по трём моделям	6
6.1	Формулы прогноза	6
6.2	Выбор основной модели для прогноза	6
6.3	Интерпретация результата	6
7	Заключение	7

1 Введение и исходные данные

В данной расчетно-графической работе исследуется зависимость скорости записи SSD накопителей (y , МБ/с) от скорости чтения (x , МБ/с).

- Объем выборки (число наблюдений): $n = 54$.
- Прогнозируемое значение фактора: $x^* = 1207.9904$.

Источник и срез

Набор данных

`openintro::ssd_speed` - SSD read and write speeds

Страница-источник

https://vincentarelbundock.github.io/Rdatasets/doc/openintro/ssd_speed.html

Как получен срез

Набор `openintro::ssd_speed` без дополнительных фильтров.

Фактор x

Скорость чтения, МБ/с (read)

Отклик y

Скорость записи, МБ/с (write)

Таблица 1: Предпросмотр данных

i	x	y
1	376.0000	361.0000
2	408.0000	419.0000
3	442.0000	385.0000
4	443.0000	381.0000
5	445.0000	389.0000
6	448.0000	390.0000
7	456.0000	418.0000
8	459.0000	420.0000
9	463.0000	428.0000
10	465.0000	407.0000
11	469.0000	359.0000
12	470.0000	391.0000
13	470.0000	389.0000
14	471.0000	433.0000
15	472.0000	394.0000

2 Диаграмма рассеяния и гипотеза о характере связи

Построена диаграмма рассеяния эмпирических данных, позволяющая визуально оценить характер зависимости между исследуемыми переменными.



Рис. 1: Диаграмма рассеяния: зависимость скорости записи от скорости чтения

Предварительная гипотеза:

С физической и технической точек зрения параметры чтения и записи накопителей тесно связаны: более современные и качественные контроллеры и чипы памяти обеспечивают высокие скорости для обоих процессов. Анализируя диаграмму рассеяния, мы наблюдаем четкую положительную корреляцию: точки образуют облако, вытянутое с нижнего левого в верхний правый угол. Можно выдвинуть гипотезу о наличии линейной или степенной/логарифмической зависимости, поскольку скорость записи может иметь технические ограничения при достижении экстремально высоких скоростей чтения.

3 Построение моделей

Для анализа выявленной зависимости были выбраны три типа моделей: линейная, квадратичная и степенная. Оценка параметров проводилась методом наименьших квадратов (МНК).

3.1 Линейная и квадратичная модели

Линейная модель имеет вид:

$$\hat{y} = a + b \cdot x \quad (1)$$

Она предполагает равномерное возрастание скорости записи при увеличении скорости чтения.

Квадратичная модель имеет вид:

$$\hat{y} = a + b \cdot x + c \cdot x^2 \quad (2)$$

Эта модель позволяет учесть возможное ускорение или замедление роста зависимой переменной (выпуклость или вогнутость кривой).

3.2 Степенная модель

Степенная модель изначально нелинейна по параметрам и имеет вид:

$$\hat{y} = a \cdot x^b \quad (3)$$

Для применения МНК необходимо провести процедуру линеаризации путем логарифмирования обеих частей уравнения:

$$\ln \hat{y} = \ln a + b \cdot \ln x \quad (4)$$

Оценив коэффициенты линейного уравнения относительно логарифмов, мы возвращаемся к исходному параметру a с помощью потенцирования: $a = e^{\ln a}$.

4 Сравнение моделей

Для оценки качества построенных моделей применяются следующие статистические метрики:

1. **Коэффициент детерминации (R^2)** — показывает долю изменчивости скорости записи, которая объясняется построенной моделью.
2. **RMSE (Root Mean Square Error)** — корень из среднеквадратичной ошибки, характеризующий абсолютную величину отклонений модели от фактических данных.
3. **Средняя ошибка аппроксимации (A)** — среднее относительное отклонение расчетных значений от фактических. Вычисляется по формуле:

$$A = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (5)$$

На основании расчетов получены следующие результаты:

Линейная: $R^2 = 0.7446$, $RMSE = 402.8958$, $A = 18.85\%$.

Квадратичная: $R^2 = 0.7542$, $RMSE = 395.2681$, $A = 18.36\%$.

Степенная: $R^2 = 0.7401$, $RMSE = 406.4618$, $A = 16.74\%$.




Рис. 2: Сравнение линий регрессии

Вывод

Наибольший коэффициент детерминации ($R^2 = 0.7542$) – эта модель объясняет чуть больше вариации зависимой переменной, чем линейная (0.7446) и степенная (0.7401).

Наименьшая среднеквадратичная ошибка ($RMSE = 395.27$) – квадратичная модель даёт наиболее точные прогнозы в абсолютных единицах (МБ/с).

Таким образом, наилучшей моделью является квадратичная, так как она обладает максимальным коэффициентом детерминации и минимальными ошибками $RMSE$ и A .

5 Анализ линейной модели

Для базовой линейной модели проведен углубленный статистический анализ.

Уравнение линейной регрессии: $y = -24.3578 + 0.9879 * x$

5.1 Остатки, RSS и дисперсия ошибки

Остатки модели e_i представляют собой разность между фактическими и расчетными значениями ($e_i = y_i - \hat{y}_i$). Остаточная сумма квадратов (RSS) равна:

$$RSS = \sum_{i=1}^n e_i^2 = 8765550.3121 \quad (6)$$

Оценка дисперсии ошибки (s^2), учитывающая потерю двух степеней свободы на оценку параметров a и b :

$$s^2 = \frac{RSS}{n - 2} = 168568.2752 \quad (7)$$

5.2 Доверительные интервалы для коэффициентов

С использованием критического значения распределения Стьюдента для доверительной вероятности $\gamma = 0.95$ и числа степеней свободы $df = 52$, построены доверительные интервалы:

- Для свободного члена a : $[-237.9161; 189.2006]$
- Для коэффициента наклона b : $[0.8269; 1.1489]$

Поскольку доверительный интервал для коэффициента b не включает в себя ноль, гипотеза о значимости связи между скоростью чтения и записи подтверждается.

6 Прогноз по трём моделям

Для заданного значения скорости чтения $x^* = 1207.9904$ МБ/с вычислен точечный прогноз скорости записи по каждой из построенных моделей.

6.1 Формулы прогноза

- **Линейная модель** $\hat{y} = a + b \cdot x$:

$$\hat{y}_{\text{лин}}^* = -24.3578 + 0.9879 \cdot 1207.9904 = 1169.04 \text{ МБ/с}$$

- **Квадратичная модель** $\hat{y} = a + b \cdot x + c \cdot x^2$:

$$\hat{y}_{\text{кв}}^* = -291.2995 + 1.6032 \cdot 1207.9904 - 0.0002 \cdot (1207.9904)^2 = 1290.63 \text{ МБ/с}$$

- **Степенная модель** $\hat{y} = a \cdot x^b$:

$$\hat{y}_{\text{степ}}^* = 0.6944 \cdot (1207.9904)^{1.0402} = 1116.07 \text{ МБ/с}$$

6.2 Выбор основной модели для прогноза

Основной для прогнозирования выбрана **квадратичная модель**. Ранее при сравнении моделей она показала наивысший коэффициент детерминации ($R^2 = 0.7542$) и наименьшую среднеквадратичную ошибку ($\text{RMSE} = 395.27$), что свидетельствует о её лучшей точности и адекватности исходным данным в диапазоне наблюдаемых значений.

6.3 Интерпретация результата

Согласно квадратичной модели, при скорости чтения SSD-накопителя, равной 1208 МБ/с, ожидаемая скорость записи составляет примерно 1290 МБ/с. Это означает, что

на высоких скоростях чтения прирост скорости записи несколько замедляется по сравнению с линейным трендом — технически это может объясняться достижением пропускной способности интерфейса или ограничениями контроллера памяти. Полученный прогноз может использоваться для приблизительной оценки производительности накопителей в классе высоких скоростей, однако следует помнить, что точка x^* находится за пределами основного диапазона исходных данных (максимальное наблюдаемое значение $x = 2381$ МБ/с), поэтому прогноз носит экстраполяционный характер и требует осторожной интерпретации.

7 Заключение

В работе исследовался реальный набор данных `openintro::ssd_speed`, содержащий 54 наблюдения скоростных характеристик SSD-накопителей. Изучалась зависимость скорости записи (y , МБ/с) от скорости чтения (x , МБ/с). Для описания связи были построены три регрессионные модели: линейная, квадратичная и степенная. Наилучшей по совокупности критериев признана квадратичная модель: она имеет наибольший коэффициент детерминации ($R^2 = 0.7542$) и наименьшую среднеквадратичную ошибку ($\text{RMSE} = 395.27$). Это означает, что квадратичная модель точнее других аппроксимирует реальные данные. Содержательная интерпретация: между скоростями чтения и записи существует сильная положительная нелинейная связь — при увеличении скорости чтения скорость записи также растёт, но на высоких значениях её прирост несколько замедляется. Прогноз по квадратичной модели для скорости чтения $x^* = 1207.99$ МБ/с даёт ожидаемую скорость записи около 1290 МБ/с, что может быть использовано для приблизительной оценки производительности накопителей в высокоскоростном классе.